项目编号：2026PY—

2026 年度本科生创新创业训练培育项目

中期汇报表

项目名称		SocialSense：基于多源社交媒体协同的舆情溯源与辅助预测系统
项目负责人	姓名	张艺嘉
	院系	数据科学与工程学院
	专业	数据科学与大数据技术
	手机	19980766941
	邮箱	3200287039@qq.com
指导教师姓名、职称		树杨　副教授（机器学习）
项目立项时间		2026 年 4 月

填表日期：2026 年 10 月 30 日

项目基本情况	项目选题来源 （自立项目或教师科研课题的子项目）	自主立题（☑ 自立项目）
	依托单位或合作单位 （实验室、研究中心、中小学机构等）	华东师范大学数据科学与工程学院；依托指导教师所在实验室

一、项目计划达到的目标和内容

本项目围绕多源社交媒体舆情分析中“跨平台口径难统一、生成结论难追证、未来趋势难验证”的问题，研究并实现 SocialSense 舆情溯源与辅助预测系统。项目以创新训练为定位，重点考察研究方法、系统实现、实验可复核性及学生科研能力提升，服务于公共议题观察、传播研究和辅助研判。

立项研究内容包括五个方面：一是建立多平台数据接入、字段映射、清洗和时间标准化流程，保留来源与缺失信息；二是研究平台间立场、情绪及热度差异，逐步实现同一事件的跨平台语义对齐；三是探索传播关系建模、关键节点识别及路径回溯；四是研究文本信息与热度时序协同的多步预测方法，评估方向判断、尖峰识别与数值误差；五是开发可交互分析终端及带证据引用的报告生成流程。

中期工作聚焦“数据契约—分析校准—辅助预测—交互展示”的原型闭环：形成可检查的数据接口和规则约束，完成四分量预测模型及数值推理包验证，形成可运行的三维档案终端，并梳理尚未完成的传播图和语义对齐任务。结题阶段拟补充跨话题验证、用户试用与成果材料；软件著作权和论文成果以正式回执为准，不将计划事项列为已取得成果。

二、研究进展和当前成果（2000 字以内）

（一）形成分层原型及统一数据契约

项目已建立 Flask 后端、TypeScript/Vite/Three.js 前端、单平台分析与多平台融合模块，并设置多平台适配接口。单平台以文本、时序和元数据组织输入，通过 PlatformReport 向多平台层传递结果。现有接口与样例能够支撑原型分析；六平台适配能力不等于六平台均已完成稳定在线采集。预测实验所用数据单独登记为 2023 年 1 月 1 日至 2026 年 8 月 31 日的 1339 个日度观测，避免与其他采集批次混用。

（二）建立单平台六阶段分析与证据校准流程

单平台链路依次完成采集清洗、立场画像、文本与时序分析、知识检索补充、结论生成和规则校准；编排支持 LangGraph，并保留线性执行路径。G1—G7 规则分别检查声量趋势、情绪趋势、主导立场、引用标识、年份与百分比边界、空数据表述以及风险等级与分析证据的一致性。外部检索作为背景补充，不能替代本平台观测；规则通过也不等于事实正确，关键判断仍需人工复核。目前文本侧采用 TF-IDF 等特征，尚不能表述为已完成图像、视频联合编码。

（三）实现跨平台统计对齐与受约束汇总

对齐器对各平台时间轴作外连接，保留缺失值，并在平台内标准化声量；融合器计算立场分布的 Jensen-Shannon 散度、情绪均值极差和声量相关性。主控通过 CX1—CX5 核查平台覆盖、分歧表述、引用平台、断言绑定与空窗处理。现有加权得分用于提示平台差异，尚未以用户互动网络验证回音室效应，也不能据此判定传播因果；向量级事件聚类与传播图溯源仍在后续计划中。

（四）完成四分量预测模型与可复核评估

模型将输入拆分为趋势 T、季节 S、冲击 C 和剩余项 R，分别采用线性、PatchCNN、稀疏事件和轻量状态空间编码，再以稀疏混合专家融合并输出预测增量。EMA 含可学习平滑参数；R 是代数剩余项；路由器接收四路数值表征。完整模型含可选文本增量路径，本次部署验证采用关闭文本的数值路径。

以过去 28 天预测未来 6 天，按时间划分训练 937 天、验证 135 天、测试 267 天；测试形成 262 个窗口。2026 年 10 月 19 日独立验证记录显示，数值路径方向准确率 65.53%（235 个非平坦窗口），尖峰 AUC 为 0.610；固定验证集阈值下，召回率 39.39%、精确率 38.24%。标准化 log1p 空间 MSE 为 1.889，高于持续值基线 1.525 约 23.87%，说明数值拟合与预警可用性仍有改进空间。重叠窗口并非独立样本，现阶段不作显著性或跨场景泛化结论。

（五）完成数值权重导出与交互原型

数值推理包含 49373 个参数，文件约 242.17KiB；完整检查点约 477.39MiB。CPU、with_text=False 条件下，262 个测试窗口的导出前后最大预测差为 0，验证了该数值路径的一致性，不能外推为完整文本路径等价或服务器内存表现。前端已实现三维档案浏览、详情和检索等交互；本次留存仓库本地运行截图，展示内置档案数据。下一步需补齐线上服务联调、低配置运行测量与用户试用记录。

阶段产出包括原型代码、模型权重与验证记录、文献阅读及证据索引、研究工作流和规范约束文档。传播溯源、跨平台语义对齐和成果申报材料尚需继续完善。

三、项目创新点

（项目实施过程中使用的新方法或者项目特色，600 字以内）

项目特色体现在面向舆情任务的系统组合与可核验设计，现阶段定位为方法探索和工程实现，不主张单个基础算法首创。

1. 将证据约束贯穿多平台分析。以 PlatformReport 统一模块接口，将 G1—G7 单平台规则与 CX1—CX5 跨平台规则串联，使生成结论能够回查观测、引用和风险依据。其价值在于暴露不一致和证据缺口，而非宣称消除模型幻觉。

2. 面向突发热度设计分量专属预测路径。在已有分解预测、PatchCNN 及选择性状态空间思想基础上，构建 T/S/C/R 四分量编码与稀疏专家融合，区分缓慢趋势、周期和冲击信息；其相对优势仍需消融、简单基线和跨话题实验验证。

3. 将可部署性纳入研究评价。导出约 242.17KiB 的数值推理包并验证指定路径一致性，降低权重分发成本；同时公开 MSE 未优于持续值基线的结果，将文件体积、运行资源、预测质量分别评价。

4. 以交互档案连接研究与应用。将平台来源、观测范围、结论和研究记录组织到可浏览界面，为人工复核提供入口。平台差异得分仅作为探索线索，后续以事件标注和互动网络检验解释的有效性。

四、研究心得

（项目实施过程中的得失成败，如在创新思维和成长方面有何收获，有何值得借鉴的成功经验和失败教训等，2000 字以内）

（一）研究问题需要通过可检验的指标表达

立项时，我们更多关注功能是否齐全。随着数据、模型和前端逐步联调，我们认识到，原型能够运行与研究结论成立是两件不同的事。跨平台结果必须说明平台覆盖和缺失情况，预测结果必须说明时间切分、目标空间和评价规则，截图也必须说明来自本地数据还是实时服务。把这些口径固定下来，是从完成课程式功能转向开展研究的重要一步。

（二）如实面对负结果，并保留改进依据

当前模型具备一定方向判别能力，但 MSE 仍高于持续值基线。我们不能用单一有利指标替代完整评估，也不能将尚未验证的原因写成结论。下一步需要分别检查冲击处理、幅度恢复、文本信号和专家融合的贡献，通过统一切分下的基线及消融实验定位问题。只有在误报成本、召回率和实际使用需求同时明确后，才能讨论预警的应用价值。

（三）可复现性依赖细节和边界

完整检查点与数值推理包的等价性检验，使我们进一步理解：模型名称、参数规模和文件体积都不能代替行为验证。本次数值路径一致，并不代表关闭文本与启用文本具有相同功能，也不代表低配置服务器已经通过性能验收。类似地，代码中的模块名称不能直接当作成果描述，文本特征分析不应被扩大为完整多模态感知。保持文档与实际调用路径一致，是科研记录应承担的责任。

（四）统一接口改善协作，明确责任保障进度

五位成员围绕总体架构、数据质量、预测评估、传播研究和交互实现分工。统一字段、时间格式、缺失值约定及报告结构，能够减少联调时的重复解释。后续将用“任务—负责人—证据文件—验收条件”的方式管理进度，对未达到验收条件的任务明确标注进行中，避免仅凭代码存在就判断研究已完成。

（五）调整研究节奏，优先补齐关键证据

目前传播关系数据与跨平台事件标注仍不足，相关模块进度落后于原计划。我们将先建立可人工核查的小规模样本和简单基线，再推进图模型与复杂融合；同时尽早记录部署资源、失败样例和用户反馈。文献阅读、过程留痕和负结果分析将与开发同步开展，使最终成果既能展示，也能被复核和解释。

五、项目组成员			
姓名	学号	专业	项目研究中承担的主要任务
张艺嘉	10245501451	数据科学与大数据技术	项目负责人。总体架构、接口契约与研究进度统筹；模型实现和数值导出验证；前后端集成、证据归档及经费核账。
詹江叶煜	10235501471	数据科学与大数据技术	传播溯源与跨平台事件对齐研究；传播关系字段、图构建与关键节点方法调研；后续负责标注样本及基线验证。
郑锦凡	10245000446	统计学	时序预测与评估协议设计；简单基线、消融和误差分析；方向、尖峰及误报指标复核。
王悦	10254511422	教育学部	多平台数据整理与质量检查；字段映射、时间规范及缺失记录；参与事件标注和用户需求整理。
吴珂欣	10255101562	软件工程	交互前端与三维档案终端；详情、检索和证据展示；系统联调、异常场景测试与用户反馈整理。

六、经费使用情况及下一步研究计划

（培育阶段经费的使用情况及下一步研究计划，2000 字以内）

（一）经费情况与核账安排

立项申请书列示预算合计 7500 元：云服务器 1800 元、数据采集与接口 1200 元、软件开发与模型训练 2000 元、大模型调用 1000 元、调研差旅 800 元、知识产权及论文相关 700 元。上述数字为申请书预算口径，实际获批额度与支出应依据学校财务记录确认。

原汇报草稿提出将调研差旅 800 元及软件开发与训练 400 元调整至大模型调用，形成调用 2200 元、开发训练 1600 元、差旅 0 元的分配建议，总额仍为 7500 元。当前材料未附预算调整审批、报销明细或票据，因此本表不将该建议列为已获批调整或已发生支出，也不据此判断经费结余、执行率及是否超支。

下一步由负责人汇总实际到账、采购与调用账单、报销日期及凭证编号，按预算科目建立台账，向指导教师核对后补充学校认可的实支数据；需要调剂的科目按学校流程办理。经费投入优先支持数据验证、必要算力和成果整理。

（二）2026 年 11 月至 12 月 完善证据与基础验证

固化数据版本、时间切分、模型配置和评估脚本，补充持续值、季节持续值及线性模型基线，并开展分量与专家模块消融。建立跨平台同事件标注小样本，明确来源、时间窗、标注规则及争议处理；梳理传播关系字段，先验证可追溯边与简单节点排序。验收材料包括统一评估表、错误案例、标注说明与传播关系样例，尚未完成的实验不预填结果。

（三）2027 年 1 月至 3 月 完成核心研究与系统联调

在固定协议下比较文本启停、冲击分量、专家路由和预测头；通过滚动时间切分、跨话题评估及分块重采样分析稳定性。推进语义事件对齐与传播图研究，比较简单基线和图模型，谨慎表述首发线索与因果结论。完成线上档案、报告和预测接口联调，记录资源峰值、延迟、异常降级及小规模用户试用反馈。

（四）2027 年 4 月至 6 月 整理成果并准备结题

收敛经过验证的模块，整理代码、数据说明、文献综述、实验记录、使用文档与经费台账，形成结题报告及演示材料。完善软件著作权申请材料与论文初稿，按实际进展提交；登记、录用或发表状态以正式证明为准。

风险应对：若传播关系数据不足，优先交付可核查的关键节点与时间线，不将统计先后关系写成真实传播路径；若预测未稳定优于基线，完整报告负结果，并依据误报成本评估辅助价值；若线上网络不稳定，答辩使用已核验的离线截图和本地演示。